

Systemes de recommandation

Illustrations issues du cours en ligne de
l'université de Stanford

Exemple Netflix Price

- Système de recommandation de films
- Données d'entraînement
 - 100 millions de notes
 - 480 000 utilisateurs
 - 17 770 films
 - Données de 2000-2005
- Données Test
 - Les dernières notes de chaque utilisateur (2.8 millions)

Matrix R


17,700
movies

480,000 users



1	3	4			
	3	5			5
		4	5		5
		3			
		3			
2			2		2
				5	
	2	1			1
	3			3	
1					

Matrix R



$$\text{RMSE} = \frac{1}{|R|} \sqrt{\sum_{(i,x) \in R} (\hat{r}_{xi} - r_{xi})^2}$$

True rating of user x on item i : r_{xi}

Predicted rating: \hat{r}_{xi}


Approches

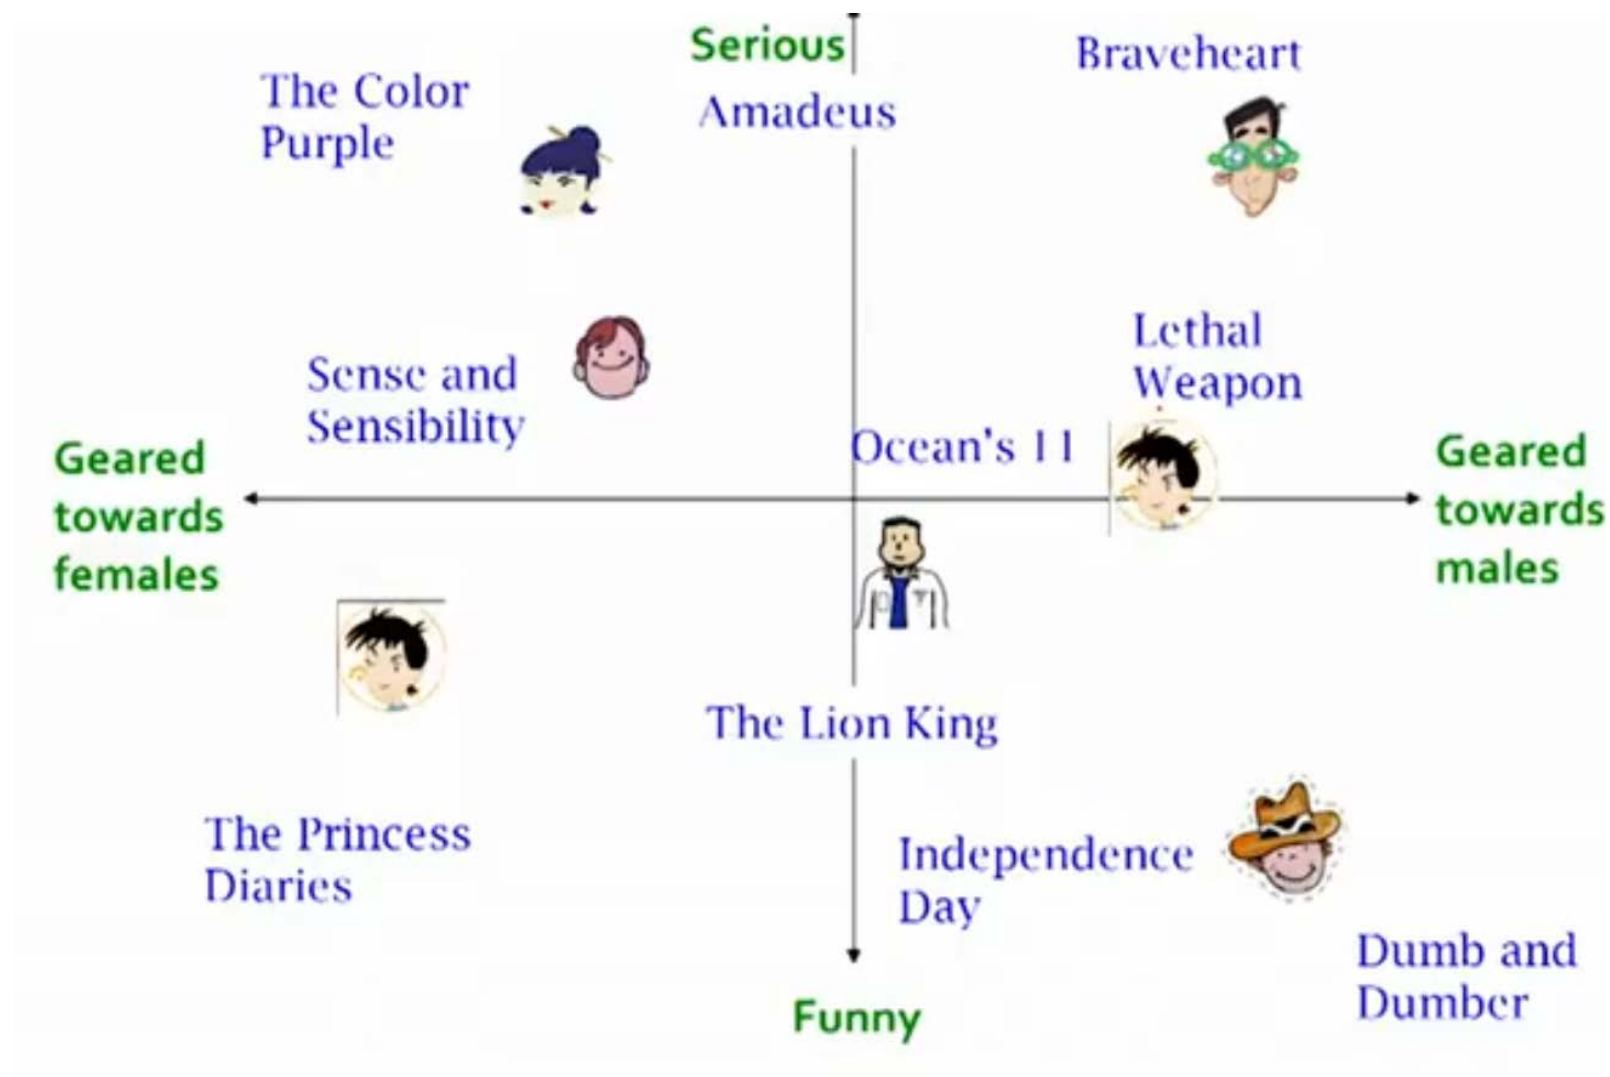
- Globale
 - Moyenne des notes des films : 3.7
 - Film i a en moyenne 0.5 points de +
 - Utilisateur x note 0.2 points en dessous de la moyenne
 - -> note de l'utilisateur x pour film i : $3.7 + 0.5 - 0.2 = 4$

Approche SVD

$$R \approx Q \cdot P^T$$

$$\text{SVD: } A = U \Sigma V^T$$





The diagram illustrates matrix factorization. It shows a 6x10 matrix of user-item ratings (yellow cells) with one cell containing a question mark. This matrix is approximated by the product of two smaller matrices, each with 3 columns (labeled 'k factors').

Items Matrix (6x3):

1	-4	2
-5	6	5
-2	3	5
1.1	2.1	3
-7	2.1	-2
-1	7	3

Users Matrix (3x10):

1	3	5	5	4					
5	4	4	2	1	3				
2	4	1	2	3	4	3	5		
2	4	5	4		2				
4	3	4	2			2	5		
1	3	3	2			4			

The approximation is shown as: $\text{Items Matrix} \times \text{Users Matrix} \approx \text{Rating Matrix}$.

$$\hat{r}_{xi} = \mathbf{q}_i \cdot \mathbf{p}_x^T$$

$$= \sum_k \mathbf{q}_{ik} \cdot \mathbf{p}_{xk}$$

\mathbf{q}_i = row i of \mathbf{Q}
 \mathbf{p}_x = column x of \mathbf{P}^T

users

1.1	-2	.3	5	-2	-5	.8	-.4	3	1.4	2.4	-.9
-.8	.7	5	1.4	.3	-1	1.4	2.9	-.7	1.2	-.1	1.3
2.1	-.4	6	1.7	2.4	.9	-.3	.4	.8	.7	-.6	.1

P^T

users

items

1		3		5		5		4	
		5	4	2.4	4		2	1	3
2	4		1	2	3	4	3	5	
	2	4		5		4		2	
		4	3	4	2			2	5
1		3		3		2		4	

≈

≈

items

f factors

Q

1	-.4	2
-.5	.6	.5
-.2	3	.5
1.1	2.1	.3
-.7	2.1	-.2
-.1	.7	.3

f factors

users

P^T

1.1	-.2	.3	5	-.2	-.5	.8	-.4	.3	1.4	2.4	-.9
-.8	.7	.5	1.4	.3	-.1	1.4	2.9	-.7	1.2	-.1	1.3
2.1	-.4	.6	1.7	2.4	.9	-.3	.4	.8	.7	-.6	.1

$$\hat{r}_{xi} = q_i \cdot p_x^T$$

$$= \sum_f q_{if} \cdot p_{xf}$$

q_i = row i of Q
 p_x = column x of P^T

SVD

- SVD donne l'erreur de reconstruction minimale (somme des erreurs au carré SSE)

$$\min_{U, V, \Sigma} \sum_{ij \in A} (A_{ij} - [U \Sigma V^T]_{ij})^2$$

- SSE et RMSE sont liés

$$RMSE = \frac{1}{c} \sqrt{SSE}$$

-> SVD minimise RMSE

- Pb : somme dans le terme d'erreur : sur toutes les entrées (notes absentes interprétées comme des 0)
- Mais données manquantes

Objectif : trouver P et Q tq

$$\min_{P,Q} \sum_{(i,x) \in R} (r_{xi} - q_i \cdot p_x^T)^2$$

The diagram illustrates the matrix factorization process. It shows a sparse matrix R (users x items) being decomposed into two matrices Q (users x factors) and P^T (factors x items).

Matrix R (users x items):

1	3			5		5	4	
		5	4		4		2	1
2	4		1	2	3	4	3	5
	2	4		5		4		2
		4	3	4	2		2	5
1	3		3		2		4	

Matrix Q (users x factors):

1	-4	2
-5	6	5
-2	3	5
11	21	3
-7	21	-2
-1	7	3


Matrix P^T (factors x items):

1.1	-2	3	5	-2	-5	8	-4	3	14	24	-9
-8	7	5	14	3	-1	14	29	-7	12	-1	13
21	-4	6	17	24	9	-3	4	8	7	-6	1

The relationship is shown as $R \approx Q P^T$.

Rappel : Minimisation d'une fonction

- Minimisation de la fonction $f(x)$
 - Calcul de la dérivée ∇f
 - Partir d'un point donné et évaluer $\nabla f(y)$
 - Pas dans la direction inverse du gradient $y = y - \nabla f(y)$
 - Répéter jusqu'à convergence



- On cherche à minimiser SSE pour des données **test** non connues
- Idée : minimiser SSE sur les données d'**entraînement**
 - On cherche des valeurs de k (nb de facteurs) pour capturer tout le signal
 - Mais sur les données **test** SSE commence à augmenter pour $k > 2$
- C'est un exemple classique d'**overfitting**
 - Avec trop de degrés de liberté (trop de paramètres libres), le modèle commence à ajuster du bruit
 - -> ajuste trop bien sur les données d'entraînement mais ne généralise pas bien aux données tests inconnues

Traitement des données manquantes

- Pour résoudre le pb d'overfitting -> on introduit une régularisation
 - Modèle riche quand les données sont suffisantes

$$\min_{P, Q} \underbrace{\sum_{\text{training}} (r_{xi} - q_i p_x^T)^2}_{\text{"error"}} + \lambda \underbrace{\left[\sum_x \|p_x\|^2 + \sum_i \|q_i\|^2 \right]}_{\text{"length"}}$$

λ ... user set regularization parameter

Descente de gradient stochastique

- On cherche les matrices P et Q tq

$$\min_{P, Q} \sum_{\text{training}} (r_{xi} - q_i p_x^T)^2 + \lambda \left[\sum_x \|p_x\|^2 + \sum_i \|q_i\|^2 \right]$$

- Descente de gradient
 - Initialisation de P et Q (en utilisant la SVD, notes manquantes mises à 0)

- $P \leftarrow P - \eta \cdot \nabla P$

- $Q \leftarrow Q - \eta \cdot \nabla Q$

where ∇Q is gradient/derivative of matrix Q :

$$\nabla Q = [\nabla q_{ik}] \text{ and } \nabla q_{ik} = \sum_x r_{xi} - 2(r_{xi} - q_i p_x^T) p_{xk} + 2\lambda q_{ik}$$

- Here q_{ik} is entry k of row q_i of matrix Q

- And similarly for ∇P